ACTIVIDAD 5

Predicción de la progresión de diabetes mediante técnicas de aprendizaje automático

Reporte técnico académico. Preparación y versionamiento de datos, entrenamiento, optimización de hiperparámetros y trazabilidad de experimentos mediante MLflow.

Fecha: 16 de octubre de 2026.

1. Introducción

El aprendizaje automático facilita la identificación de relaciones entre variables predictoras y resultados cuantitativos. El presente proyecto compara un modelo lineal regularizado con un método de ensamble para estimar la progresión de la diabetes. La finalidad es evaluar desempeño predictivo y reproducibilidad, sin atribuir utilidad clínica directa a los resultados.

2. Objetivo

Preparar y versionar un conjunto público de datos, entrenar dos algoritmos de regresión, ajustar sus hiperparámetros mediante validación cruzada, comparar métricas y disponer de un mecanismo reproducible de seguimiento en MLflow.

3. Datos, fuente y diccionario

Se utiliza Diabetes, disponible en scikit-learn y basado en el trabajo de Efron et al. (2004). Contiene 442 observaciones, diez predictores numéricos previamente escalados y una variable objetivo continua que representa progresión de la enfermedad al año. Por consiguiente, el problema es de regresión y no de clasificación diagnóstica.

Diccionario: age (edad); sex (sexo codificado); bmi (índice de masa corporal); bp (presión arterial media); s1 (colesterol total); s2 (LDL); s3 (HDL); s4 (relación colesterol total/HDL); s5 (logaritmo de triglicéridos); s6 (glucemia); target (medida de progresión). Los predictores se proporcionan estandarizados y no deben interpretarse como medidas clínicas en sus unidades originales.

4. Limpieza, estandarización y versionamiento

Se conservaron 442 registros originales y 442 registros tras la limpieza. Se verificó el esquema de columnas, se convirtieron predictores y objetivo a formato numérico, se eliminaron duplicados y se descartaron observaciones sin variable objetivo. El pipeline utiliza imputación por mediana aprendida únicamente en entrenamiento; Ridge incorpora estandarización adicional. No existen variables categóricas nominales que requieran codificación one-hot. El sexo se conserva en su representación numérica original. Los archivos CSV originales y limpios se guardan por separado y se registran hashes SHA-256; el historial está documentado en CHANGELOG.md.

5. Análisis exploratorio

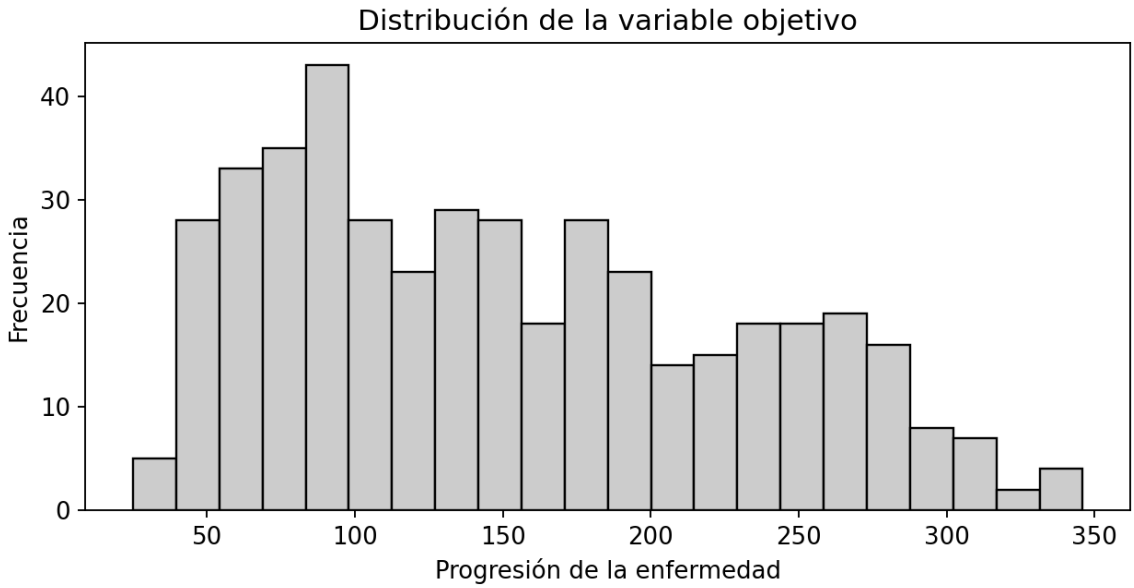


Figura 1. Distribución de la variable objetivo. La dispersión observada refleja heterogeneidad en la medida de progresión. El histograma permite identificar asimetrías y concentración de valores, pero no demuestra causalidad.

6. Diseño experimental

Se reservó 20 % de las observaciones para prueba y 80 % para entrenamiento, con random_state=42. Dentro del conjunto de entrenamiento se aplicó validación cruzada KFold con cinco particiones, mezcla aleatoria y semilla fija. GridSearchCV seleccionó hiperparámetros por minimización del RMSE promedio de validación. Se entrenó Ridge con alpha en {0.1, 1, 10, 100} y Random Forest con n_estimators en {100, 200}, max_depth en {3, 6, sin límite} y min_samples_leaf en {1, 3}.

7. Resultados cuantitativos

Modelo	MAE prueba	RMSE prueba	R^2 prueba
Ridge	42.812	53.777	0.454
RandomForest	43.934	54.023	0.449

Tabla 1. Métricas sobre el conjunto de prueba. MAE y RMSE menores representan menor error; un R^2 mayor indica mejor ajuste respecto de una predicción constante basada en la media.

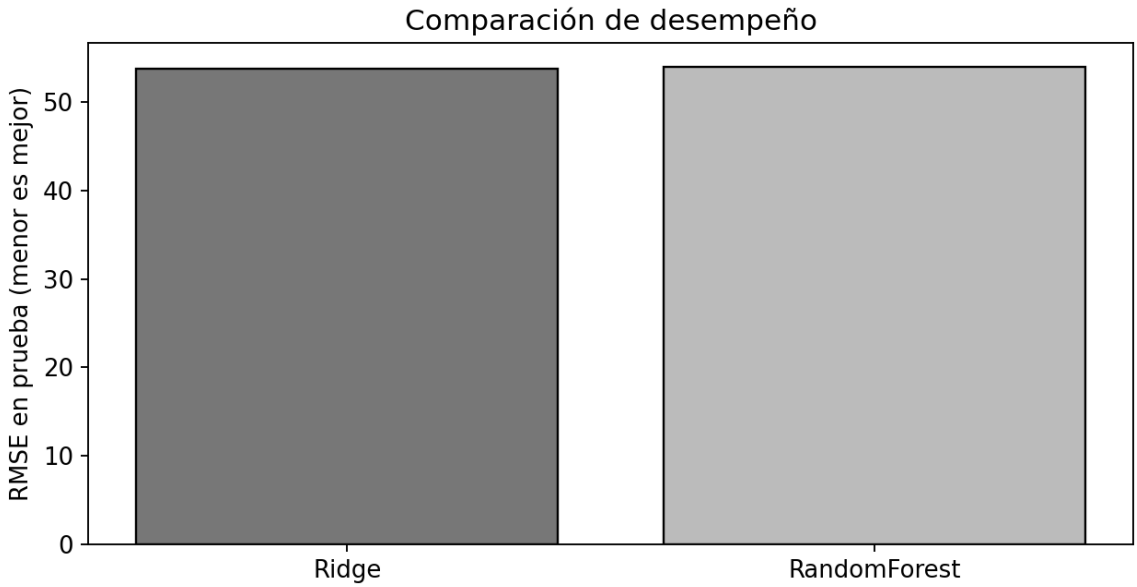


Figura 2. Comparación del RMSE sobre datos no utilizados durante el entrenamiento ni la selección de hiperparámetros.

En esta ejecución, Ridge obtuvo el menor RMSE de prueba (53.777). La comparación corresponde a una única división de prueba y no debe interpretarse como evidencia de superioridad universal. Los resultados de validación cruzada y los parámetros seleccionados se conservan en resultados/metricas_modelos.csv.

8. Comparación estadística

Se realizó una prueba t pareada exploratoria sobre los cinco valores de RMSE de validación cruzada, obteniendo t = -4.675 y p = 0.0095. Debido a que los subconjuntos de entrenamiento de los folds se superponen, las observaciones no son plenamente independientes; por ello, el valor p no constituye una prueba inferencial concluyente. Se recomienda repetir la validación cruzada o utilizar validación externa para fortalecer la evidencia.

9. Trazabilidad y MLflow

El archivo fuentes/train.py configura un experimento denominado Actividad5_Diabetes_Regresion y registra, para cada modelo, parámetros óptimos, métricas de prueba y validación, el pipeline ajustado y una copia del conjunto limpio. El seguimiento se activa al ejecutar el script en un entorno que tenga MLflow instalado. Durante la elaboración de este paquete, MLflow no estuvo disponible; por integridad académica no se incluyen capturas ni registros simulados. El archivo evidencias/mlflow/INSTRUCCIONES.txt detalla cómo generar y conservar capturas auténticas del panel.

10. Deuda técnica, MLOps y limitaciones

Las principales fuentes de deuda técnica incluyen dependencia de versiones de bibliotecas, tamaño limitado de muestra, ausencia de validación externa, variación de desempeño entre particiones y riesgo de interpretar predictores escalados como unidades clínicas. Como prácticas MLOps se incorporan semillas fijas, separación de datos, pipelines que evitan fuga de información, registro de versiones, hashes, experimentos y artefactos. Una implementación productiva exigiría controles de privacidad, pruebas automáticas, supervisión de deriva, revisión ética y monitoreo de desempeño.

11. Conclusiones

La actividad demuestra un flujo reproducible de regresión supervisada con preparación de datos, comparación de modelos, búsqueda de hiperparámetros y evaluación cuantitativa. Los resultados deben interpretarse como ejercicio metodológico y no como instrumento clínico. La ejecución posterior con MLflow permite completar la evidencia visual y verificar el seguimiento de los experimentos.

12. Referencias

Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least angle regression. The Annals of Statistics, 32(2), 407-499. https://doi.org/10.1214/009053604000000067

Scikit-learn developers. (s. f.). load_diabetes. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html

MLflow Project. (s. f.). MLflow Tracking. https://mlflow.org/docs/latest/ml/tracking/